AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE

Wykorzystanie sieci neuronowych do przetwarzania sygnałów biomedycznych w ocenie ryzyka patologii

Autor: Przemysław Janiszewski
Promotor: Krzysztof Regulski
Recenzent: Izabela Olejarczyk-Wożeńska
Rodzaj studiów i kierunek: stacjonarne IT, inż

Nazwa wydziału: Wydział Inżynierii Metali i Informatyki Przemysłowej
Nazwa katedry: Katedra Informatyki Stosowanej i Modelowania

Miejsce i data prezentacji: Kraków, 03.02.2025

Motywacja

- **Problematyka:**

Dynamicznie postępujący rozwój sztucznej inteligencji, a także narastające trudności w dostępie do opieki medycznej wynikające z problemów demograficznych, niewystarczającej ilości personelu medycznego oraz coraz większego rozwarstwiania się społeczeństw.

- **Cel pracy:**

Stworzenie systemu ekspertowego umożliwiającego prowadzenie badań przesiewowych dla dolegliwości cywilizacyjnych, takich jak cukrzyca, czy choroby wieńcowe, a także zapewnienie szybkich analiz i odpowiedzi na proste, rutynowe pytania w celu odciążenia personelu medycznego.

- **Kluczowe etapy realizacji projektu:**

- Trening modelu do oceny ryzyka wystąpienia zaburzeń sercowo-naczyniowych przy wykorzystaniu architektury MLP
- Szkolenie modelu do prognozowania ryzyka rozwoju cukrzycy przy zastosowaniu mechanizmu samouwagi architektury TabNet
- Implementacja oraz konfiguracja modelu LLaMA3.1 dla celów okołomedycznych

- **Założenia techniczne:**

- Dostęp do systemu z dowolnego miejsca na świecie poprzez hostowanie aplikacji w chmurze Microsoft Azure
- Ochrona danych przed nieautoryzowanym dostępem poprzez szyfrowanie komunikacji przy pomocy protokołu HTTPS, wykorzystanie reverse proxy, a także grup zabezpieczeń sieciowych (NSG)

Projekt systemu

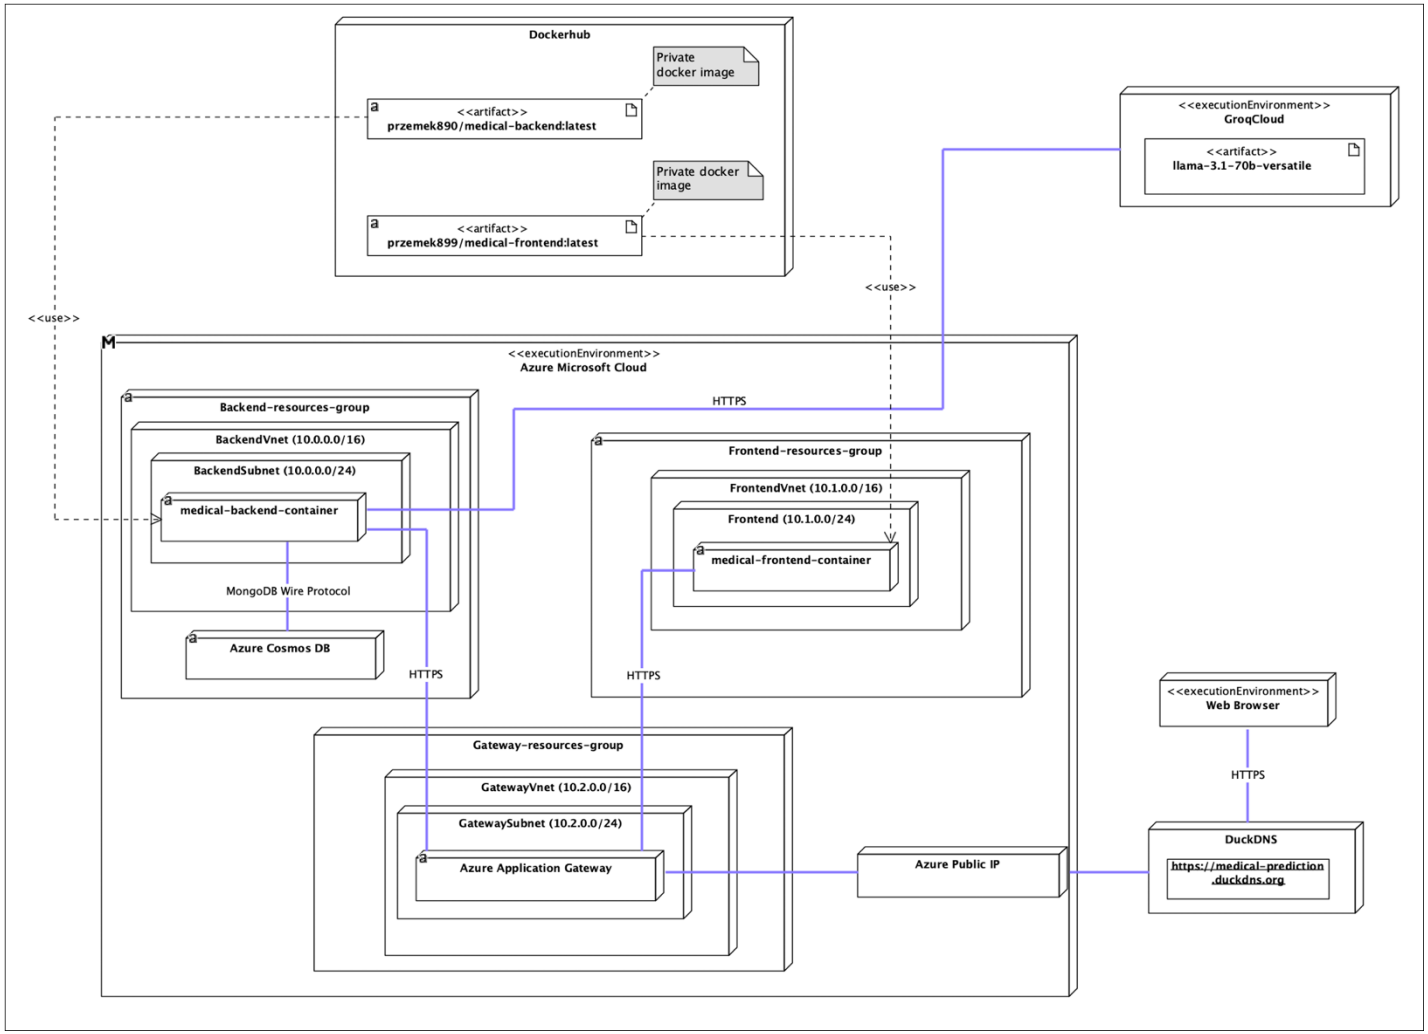

Przykłady zastosowanych technologii

Graficzny interfejs użytkownika

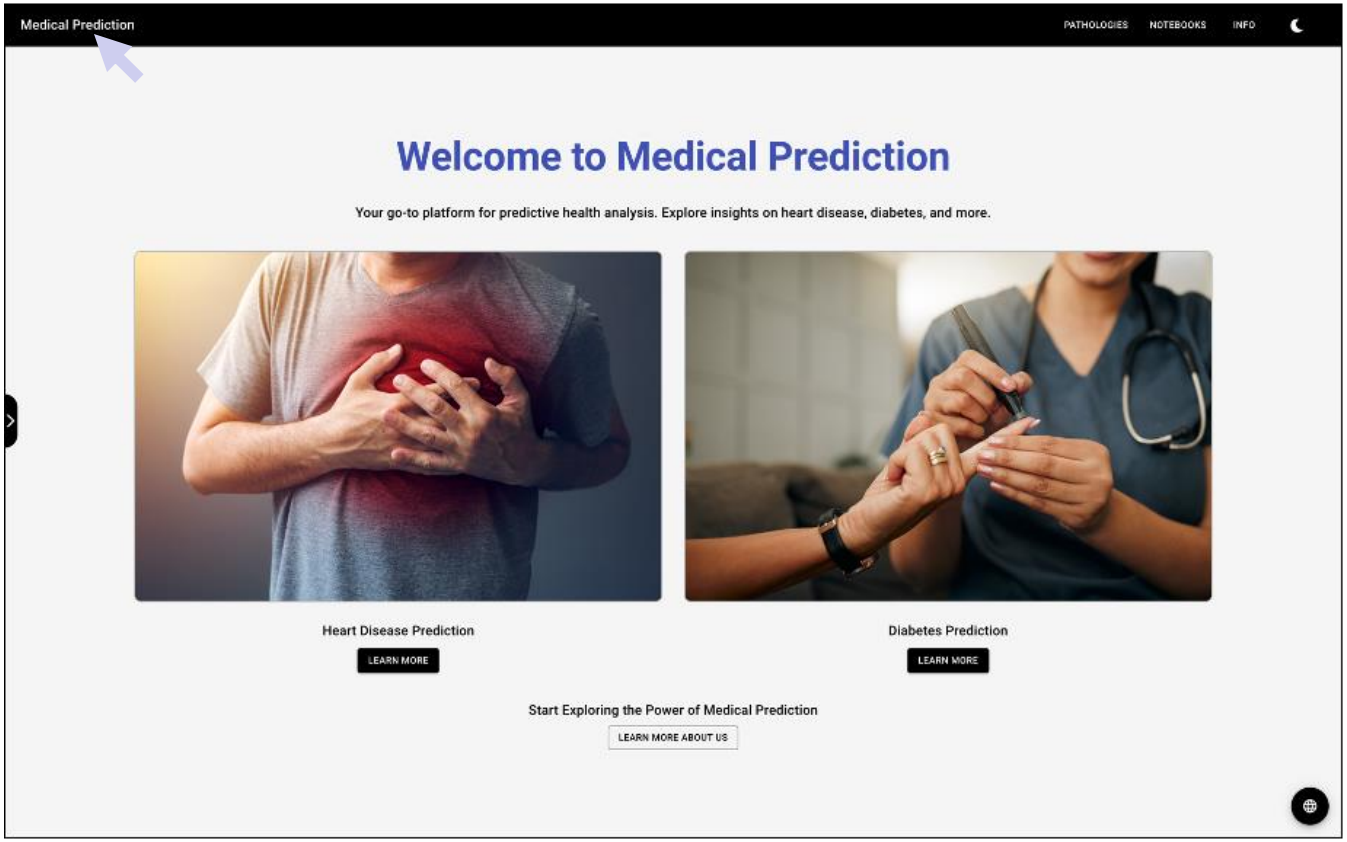

Widok dla urządzeń desktopowych

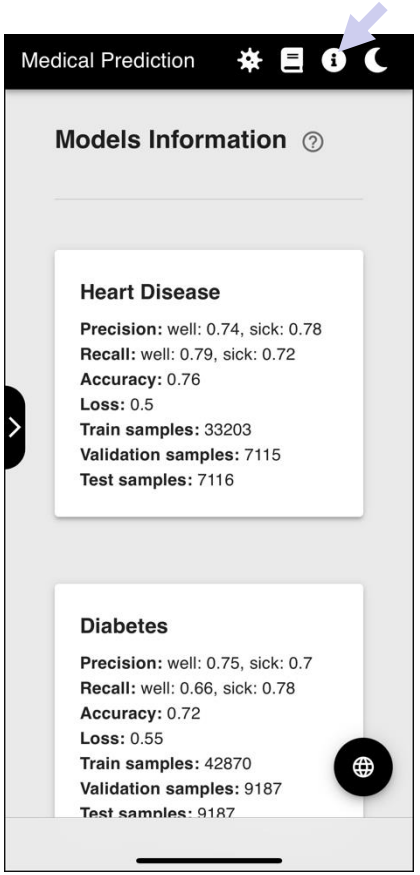

Widok dla urządzeń mobilnych

Notatniki Jupyter w postaci plików PDF, przekonwertowane z wykorzystaniem LaTeX, osadzone w oknie przeglądarki

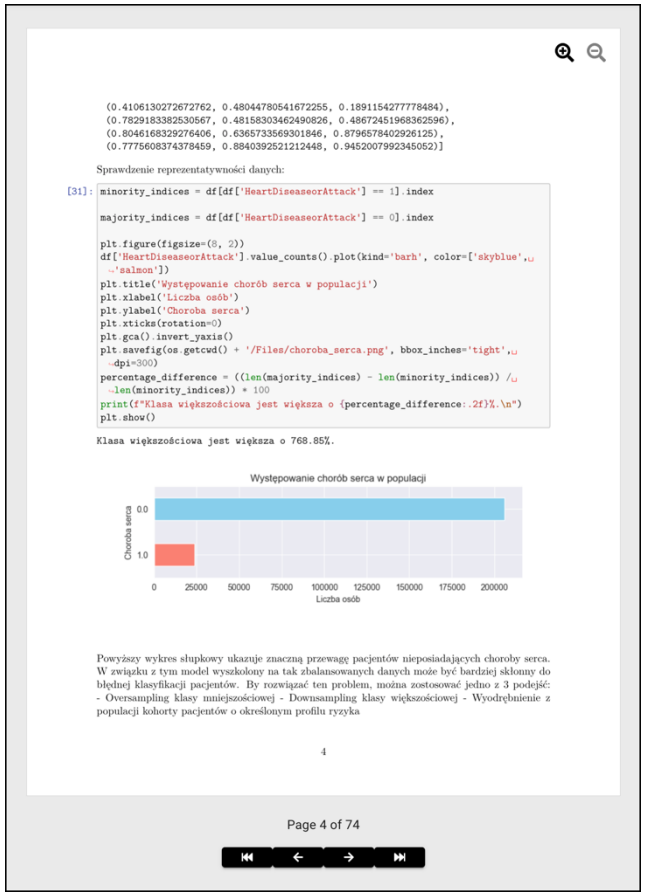

Analiza zaburzeń sercowo-naczyniowych

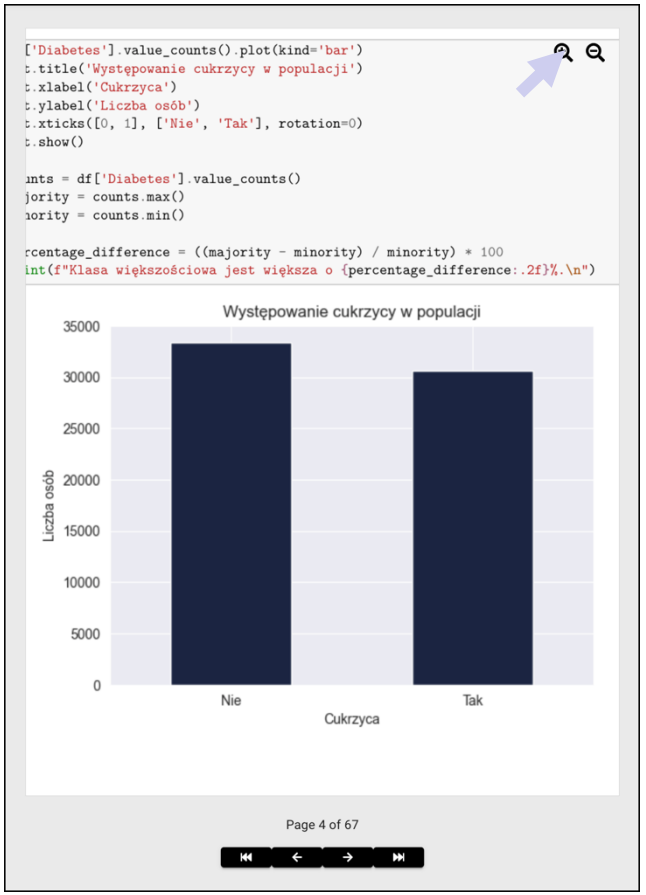

Analiza ryzyka wystąpienia cukrzycy

Architektura modeli sieci neuronowych oraz obiektu żądania

```python
import torch
import torch.nn as nn
"""""""""""""""""""""""""""

class Model_1(nn.Module):

    def __init__(self):
        super(Model_1, self).__init__()
        self.hidden1 = nn.Linear(21, 15)
        self.bn1 = nn.BatchNorm1d(15)
        self.dropout1 = nn.Dropout(p=0.3)
        self.act1 = nn.LeakyReLU(negative_slope=0.01)

        self.hidden2 = nn.Linear(15, 10)
        self.bn2 = nn.BatchNorm1d(10)
        self.dropout2 = nn.Dropout(p=0.3)
        self.act2 = nn.LeakyReLU(negative_slope=0.01)

        self.hidden3 = nn.Linear(10, 5)
        self.bn3 = nn.BatchNorm1d(5)
        self.dropout3 = nn.Dropout(p=0.3)
        self.act3 = nn.LeakyReLU(negative_slope=0.01)

        self.output = nn.Linear(5, 1)


    def forward(self, x):
        x = self.act1(self.dropout1(self.bn1(self.hidden1(x))))
        x = self.act2(self.dropout2(self.bn2(self.hidden2(x))))
        x = self.act3(self.dropout3(self.bn3(self.hidden3(x))))
        x = self.output(x)
        return x
```

```python
from pytorch_tabnet.tab_model import TabNetClassifier
import torch
"""""""""""""""""""""""""""

class Model_2:

    def __init__(self, input_dim=17, output_dim=1):
        self.model = TabNetClassifier(
            input_dim=input_dim,
            output_dim=output_dim,
            n_d=8, n_a=8,
            n_steps=3,
            gamma=1.3,
            lambda_sparse=1e-3,
            optimizer_fn=torch.optim.AdamW,
            optimizer_params=dict(lr=0.0001),
            mask_type="sparsemax"
        )
```

```python
model: str = os.getenv("GROQ_GPT_MODEL", "llama-3.1-70b-versatile")
completion = client.chat.completions.create(
    model=model,
    messages=[
        {"role": "system", "content": system_message},
        {"role": "user", "content": user_message}
    ],
    temperature=0.3,
    max_tokens=8000,
    top_p=0.5,
    stream=True,
    stop=None
)
for chunk in completion:
    yield chunk.choices[0].delta.content or ""
```

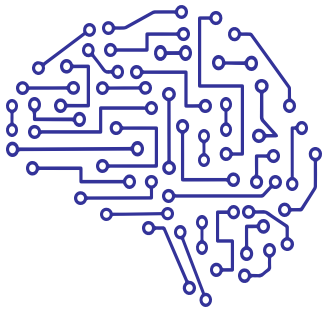

Testy systemu E2E

- Weryfikacja poprawności pobierania i wyświetlania parametrów szkoleniowych modeli z chmurowej bazy danych w sekcji Info
- Obsługa formularzy diagnostycznych // weryfikacja generowanych predykcji
- Obsługa i nawigacja po notatnikach zawierających informacje o procesie szkolenia modeli
- Zmiana języka // motywu aplikacji
- Testy funkcjonalności chatbota „Medical GPT”

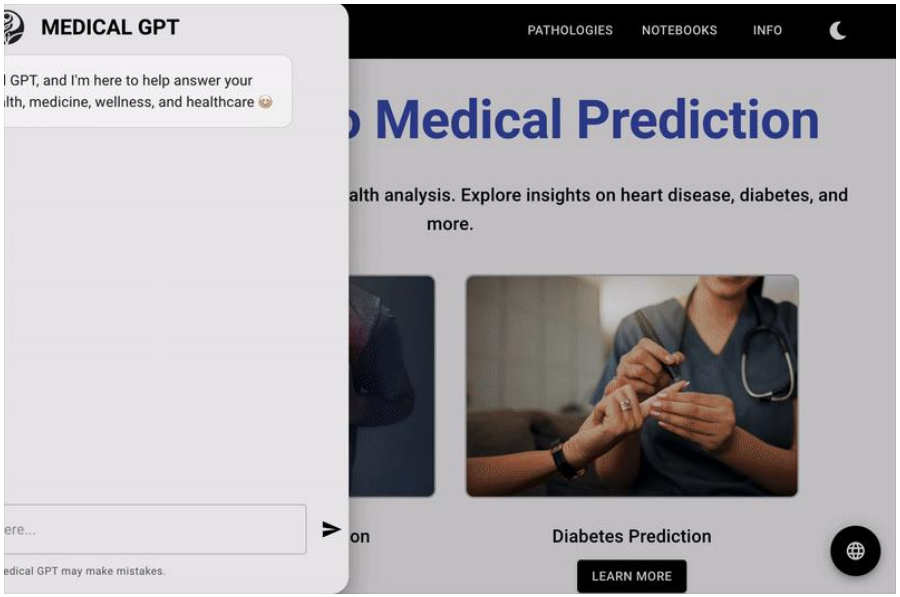

Test utrzymywanie kontekstu rozmowy oraz wyszukiwania kluczowych informacji w bazie danych przy pomocy GPT

Testy systemu

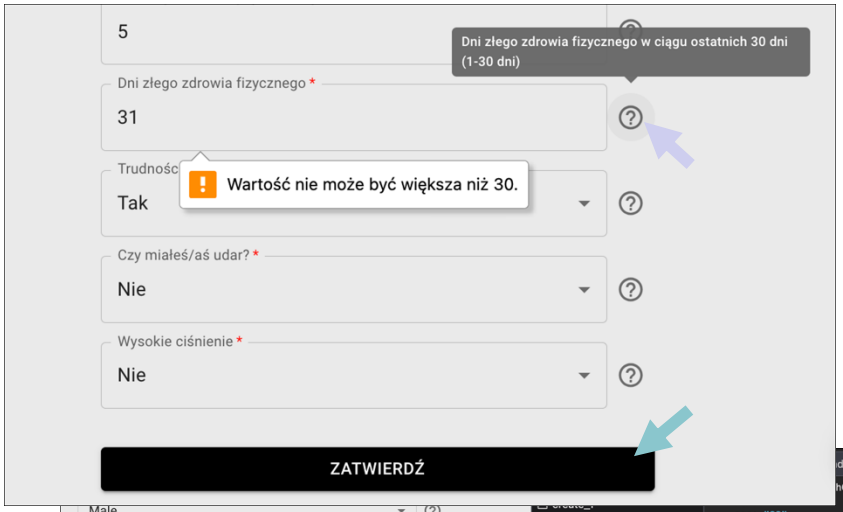

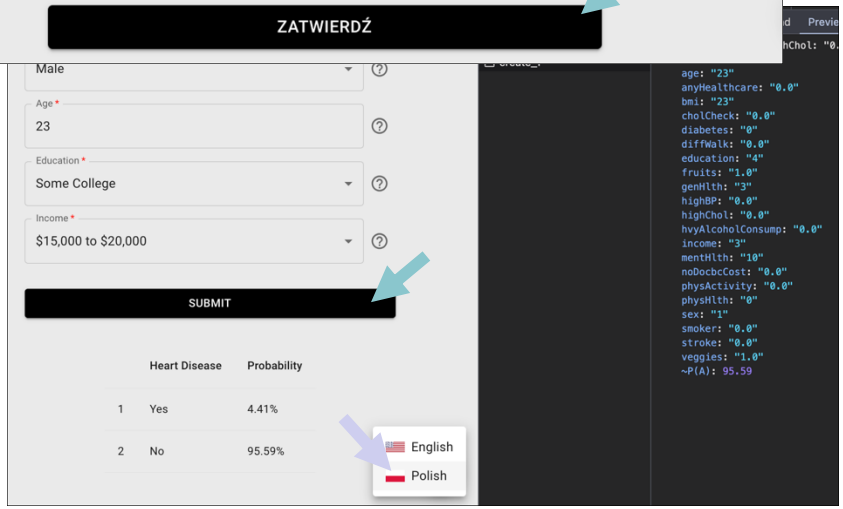

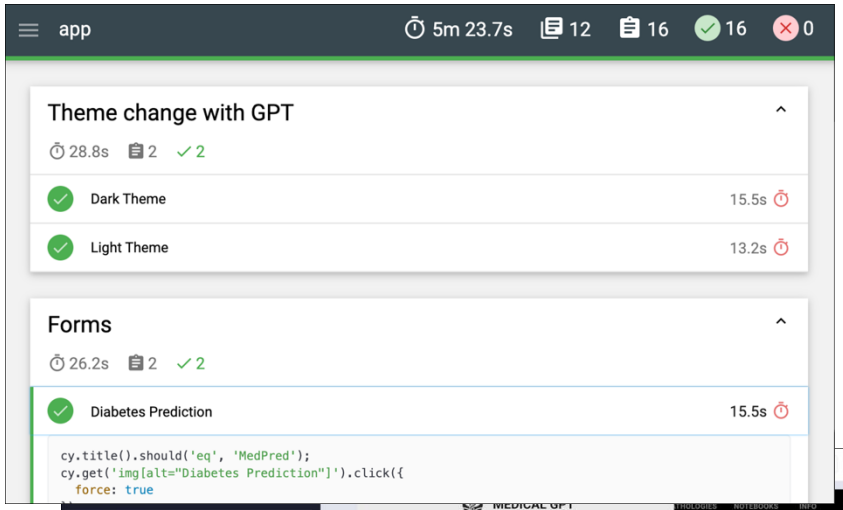

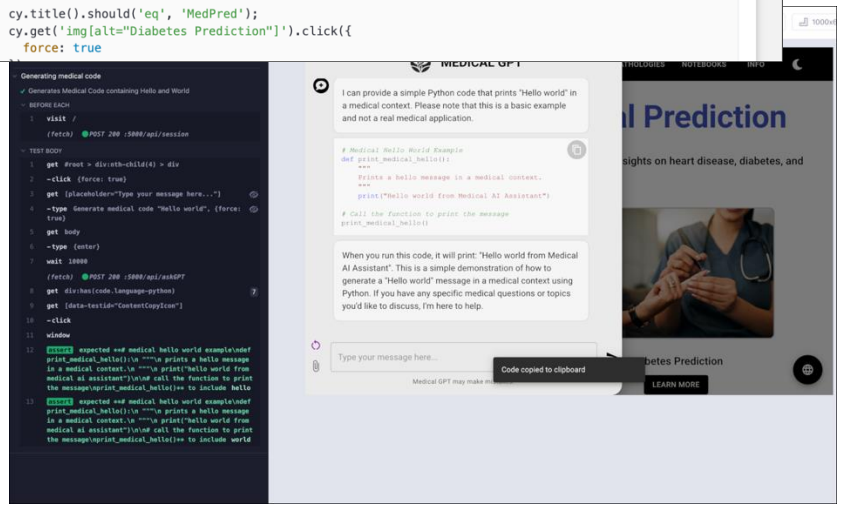

Podsumowanie

- **Dalsze możliwości rozwoju:**
  - Zapewnienie autoskalowania, replikacji i równoważenie obciążenia poprez Managed Kubernetes Service (AKS)
  - Optymalizacja zapytań bazodanowych oraz zwiększenie liczby dostępnych specjalistów medycznych
  - Implementację innych, nowatorskich modeli uczenia maszynowego
  - Zwiększenie intuicyjności interfejsu użytkownika poprzez optymalizację UI/UX
  - Udoskonalenie chatbota „Medical GPT” poprzez weryfikację dostarczanych informacji w oparciu o źródła dostępne w Internecie oraz rozwój bardziej zaawansowanych technik „prompt-to-action”
  - Rozwój większej liczby testów E2E oraz ich innych rodzajów tj. jednostkowe, bezpieczeństwa, wydajnościowe, A/B ...
- **Ocena skuteczności opracowanego rozwiązania**
- **Czy założony cel opracowanego systemu został osiągnięty?**

Dziękuję za uwagę, czekam na Państwa „zapytania” 😄